

## Neuralne mreže (13S053NM)


### Prvi projektni zadatak

#### Dataset i podaci

Dataset korišćen za ovaj projekat su slike voća. Potrebno je izvršiti klasifikaciju slika primenom dubokog učenja na tri klase – jabuke, banane i narandže.



Dati podaci su balansirani, sa tačno istim brojem slika po klasi.



Podaci su podeljeni na skup za treniranje i na skup za validaciju, tako da 80% od ukupnog broja podataka pripada skupu za treniranje, a ostalih 20% skupu za validaciju.

Podela je izvršena da bismo videli realne performanse naše mreže, jer je potrebno procenu izvršiti na nezavisnim podacima, koje model nije video tokom obuke.

```
Found 270 files belonging to 3 classes.  
Using 216 files for training.
```

```
Found 270 files belonging to 3 classes.  
Using 54 files for validation.  
['apple', 'banana', 'orange']
```

Od 270 slika (svaka klasa sadrži po 90 slika), 216 je izabrano za trening, a ostalih 54 je ostavljeno za validaciju.

Predprocesiranje podataka se vrši skaliranjem vrednosti piksela na ulazu sa opsega [0-255] na [0,1]. Vrš se i augmentacija podataka tokom treninga, radi povećavanja otpornosti na promene ulaznih podataka i povećanja skupa podataka za trening.



## Neuralna mreža

Za aktivacionu funkciju neurona izabrana je “*ReLU*” funkcija, zbog njene jednostavnosti i efikasnosti, kao i nepostojanja problema nestajućeg gradijenta.

U poslednjem sloju aktivaciona funkcija neurona je “*softmax*” funkcija, koja je ključna za višeklasnu klasifikaciju jer omogućava mreži da izračuna verovatnoću da ulazni podatak pripada svakoj od klasa, na osnovu čega se donosi odluka o konačnoj klasifikaciji.

Kriterijumska funkcija je “*sparse categorical crossentropy*” zbog postojanja više klasa i za njenu optimizaciju uzet je “*Adamov optimizer*”, koji je jedan od najčešće korišćenih optimizatora, zbog svoje efikasnosti i stabilnosti.

Arhitektura modela:


1. Predprocesirajući sloj koji vrši augmenatciju i skaliranje
2. Konvolucioni sloj koji koristi 4 filtera veličine 3x3 i “same padding-om”
3. Max pooling sloj sa podrazumevanom konfiguracijom 2x2 filterom
4. Dropout sloj koji slučajno isključuje neurone sa verovatnoćom 20%
5. Konvolucioni sloj koji koristi 8 filtera veličine 3x3 i “same padding-om”
6. Max pooling sloj sa podrazumevanom konfiguracijom 2x2 filterom
7. Dropout sloj koji slučajno isključuje neurone sa verovatnoćom 20%
8. Flatten sloj, koji vrši ravnjanje izlaza iz prethodnog sloja pretvarajući ga u 1D vektor
9. Potpuno (gusto) povezan sloj sa 16 neurona i ReLu aktivacionom funkcijom
10. Potpuno (gusto) povezan izlazni sloj sa 3 neurona i softmax aktivacionom funkcijom

Preobučavanje je pojava u neuralnim mrežama gde mreža dobro uči na trening podacima, ali prikazuje slabe rezultate na novim podacima. Ova pojava nastaje kada su parametri mreže previše prilagođeni trening skupu, što rezultuje osetljivošću na male promene u ulaznim podacima i velikim promenama u izlazu mreže. Preobučavanje može biti rezultat prevelike kompleksnosti mreže (veliki broj parametra koji se obučavaju) i prevelikog broja epoha obučavanja.

U projektu je primenjena dropout tehnika u svim skrivenim slojevima. Dropout tehnika slučajno i sa određenom verovatnoćom u svakoj iteraciji bira određen broj neurona u sloju koji se ignorišu. Ovo sprečava model da se previše oslanja na određene težine i neurone.

## Rezultati obučenog modela



Vrši se trideset epoha obučavanja. Prikazani su grafici tačnosti i kriterijumske funkcije na skupu za treniranje i na skupu za validaciju:



Tačnost modela na trening skupu je: 84.72222222222221%

Tačnost modela na skupu za validaciju je: 81.48148148148148%

Matrice konfuzije na trening i test skupu:



Primer dobro klasifikovanog primera dataset-a:

apple



banana



orange



Primer loše klasifikovanog primera dataset-a:

orange



orange



banana

